



STATISTIQUE INFERENTIELLE

FICHE DE TRAVAUX DIRIGÉS

LEG 2

I-Connaissances du cours

1-Définir **Test statistique, région critique, risque de première espèce, risque de seconde espèce et puissance d'un test**

Test statistique : une règle de décision relative à une hypothèse sur la distribution (*ensemble des valeurs prises par cette variable suivant une loi de probabilité classique ou inconnue*) d'une variable d'intérêt dans la population, qui se fonde sur les observations d'un échantillon. Il s'agit d'une procédure qui permet de contrôler ou de minimiser, suivant les cas, les risques associés à la décision.

Région critique : ensemble de réalisations de la statistique de test pour lesquelles l'hypothèse nulle du test est rejetée. La statistique de test peut être, par exemple la moyenne empirique, la variance empirique ou un autre paramètre d'une loi.

Risque de première espèce : risque de rejeter l'hypothèse nulle H_0 alors qu'elle est effectivement vraie dans la population

Risque de seconde espèce : risque de ne pas rejeter l'hypothèse nulle H_0 alors que l'hypothèse alternative H_1 est valide dans la population.

La **puissance** d'un test correspond à la probabilité de rejet de l'hypothèse nulle H_0 alors que l'hypothèse alternative H_1 est vraie. C'est la probabilité d'être dans la région critique (et donc de rejeter l'hypothèse nulle) alors que l'hypothèse alternative H_1 est vraie dans la population.

2-Quel autre nom peut-on encore donner à la théorie des tests ?

Rep : Statistique décisionnelle ou business intelligence

3-Quel est le principal avantage d'un test statistique ?

Rep : il permet de mesurer ou de contrôler les risques associés à cette décision. C'est pourquoi ces tests sont très utilisés en pratique.

4-Citer et expliquer deux ou trois exemples d'application de la Statistique décisionnelle dans la vie quotidienne.

Exemple 1 : lorsque vous sollicitez un prêt à la consommation ou un prêt immobilier auprès d'une banque, celle-ci cherche à déterminer si vous êtes un bon client, c'est-à-dire si vous serez apte à rembourser le capital et les intérêts dans le futur. Afin de savoir si vous êtes un bon client ou pas, la banque teste l'hypothèse nulle(encore appelée hypothèse de référence) selon laquelle vous êtes un bon client, et à définir une règle de décision du type rejet (ce qui implique un rejet du prêt) ou non-rejet (ce qui implique une acceptation du prêt) de cette hypothèse nulle. Un formulaire vous est ainsi adressé et à chaque réponse que vous donnez est attribué un score : c'est la **méthode du scoring**

Exemple 2 : une entreprise qui souhaite analyser l'impact d'une campagne marketing à partir d'un échantillon des ventes. Elle formalise en définissant une hypothèse nulle selon laquelle la campagne n'a pas eu d'impact, et construit une règle de décision à partir de l'échantillon permettant de conclure quant au rejet ou non de cette hypothèse.

Exemple 3 : Test d'indépendance

Il peut arriver qu'une entreprise cherche à savoir si les ventes de deux produits sont liées ou au contraire elles sont indépendantes. Le test d'indépendance peut donc être utilisé pour répondre à cette question.

5-Quels sont les éléments structurant un test statistique?

Rep : 1- Une hypothèse nulle et une hypothèse alternative

2- Une région critique fondée sur une statistique de test et une valeur critique

3- Des risques de première espèce et de seconde espèce

6-Quelles sont les deux grandes familles de tests statistiques ?

Rep : 1-Les **tests paramétriques**: portent sur la valeur d'un ou de plusieurs paramètres de la distribution dans la population d'une variable d'intérêt. Dans ces tests, l'hypothèse nulle et l'hypothèse alternative portent sur la valeur d'un paramètre de la distribution d'une variable aléatoire.

2- Les **tests non-paramétriques** : portent sur la distribution, les moments (espérance, variance, etc.) ou certaines caractéristiques (l'indépendance par exemple) d'une ou de plusieurs variables aléatoires.

7-Donner la forme d'un test bilatéral, unilatéral à gauche, unilatéral à droite

Rep : 1-Test bilatéral $H_0 : \theta = \theta_0$
 $H_1 : \theta \neq \theta_0$

2-Test unilatéral à gauche $H_0 : \theta = \theta_0$
 $H_1 : \theta < \theta_0$

3-Test unilatéral droit $H_0 : \theta = \theta_0$
 $H_1 : \theta > \theta_0$

II-Échantillonnage et Estimation

Exercice 1

On dispose d'un échantillon $(X_1, X_2, \dots, X_n)$ d'une variable X qui suit une loi normale d'espérance inconnue m et d'écart-type $\sigma = 2$ pour choisir entre les deux hypothèses :

$$H_0 : m = 2$$

$$H_1 : m = 3$$

1-Déterminer la région critique du test de Neyman et Pearson et calculer sa puissance dans le cas où $n = 100$ et $\alpha = 0,05$.

2- Quelle devrait être la taille d'échantillon minimum pour que cette puissance soit supérieure à 0,95? 0,99?

Solution :

1-la région critique définie par Neyman et Pearson est de la forme :

$$\frac{L_0(x_1, x_2, \dots, x_n, \theta_0)}{L_1(x_1, x_2, \dots, x_n, \theta_1)} = \frac{\frac{1}{2\sqrt{2\pi}} e^{\frac{-1}{2\sigma^2} \sum (x_i - 2)^2}}{\frac{1}{2\sqrt{2\pi}} e^{\frac{-1}{2\sigma^2} \sum (x_i - 3)^2}} = \frac{e^{\frac{-1}{2\sigma^2} \sum (x_i - 2)^2}}{e^{\frac{-1}{2\sigma^2} \sum (x_i - 3)^2}} \leq k. \text{ La forme logarithmique de ce rapport}$$

est $\ln \frac{L_0}{L_1} = \frac{-1}{2\sigma^2} \sum (x_i - 2)^2 + \frac{-1}{2\sigma^2} \sum (x_i - 3)^2 = \frac{-1}{2\sigma^2} \sum [(x_i - 2)^2 - (x_i - 3)^2] \leq \ln k$. Le développement de cette expression conduit à

$$\sum x_i \geq \frac{5n}{2} - \sigma^2 \ln k \Leftrightarrow \bar{x}_n \geq \frac{5}{2} - \frac{\sigma^2 \ln k}{n} \geq C : \text{c'est la forme de la région critique. La valeur de } C \text{ est}$$

déterminée en considérant le risque de rejeter l'hypothèse nulle alors même qu'elle est vraie. Cette valeur de C permet de préciser totalement la région critique.

$$\alpha = P(H_1 / H_0) = P(\bar{x}_n \geq C / m = 2) = P\left(\frac{\bar{x}_n - 2}{2/\sqrt{n}} \geq \frac{C - 2}{2/\sqrt{n}} / m = 2\right) = P\left(Z \geq \frac{C - 2}{2/\sqrt{n}}\right)$$

$$P\left(Z \geq \frac{C - 2}{2/\sqrt{n}}\right) = 1 - P\left(Z \leq \frac{C - 2}{2/\sqrt{n}}\right) = 1 - F\left(\frac{C - 2}{2/\sqrt{n}}\right) = 0,05 \Leftrightarrow F\left(\frac{C - 2}{2/\sqrt{n}}\right) = 1 - 0,05 = 0,95.$$

Par lecture et interpolation des valeurs tabulées (cf.table statistique), on a :

$$F\left(\frac{C - 2}{2/\sqrt{n}}\right) = F(1,645) \Leftrightarrow \frac{C - 2}{2/\sqrt{n}} = 1,645 \Leftrightarrow C = 2,329.$$

La région critique est $R_0 = \{(x_1, x_2, \dots, x_n) / \bar{x}_n \geq 2,329\}$.

La puissance du test quant à elle est

$$\eta = P(\bar{x}_n \geq 2,329 / m = 3) = P\left(\frac{\bar{x}_n - 3}{2/\sqrt{100}} \geq \frac{2,329 - 3}{2/\sqrt{100}}\right). \text{Par lecture sur la table statistique, on a}$$

$$\eta = P(Z \geq -3,55) = 0,999841$$

2-Taille minimum à choisir pour

$$\diamond \quad \eta \geq 0,95$$

On sait que $\eta = P(\bar{x}_n \geq C / m = 3) = P\left(\bar{x}_n \geq 2 + \frac{2}{\sqrt{n}}\right) = P\left(\frac{\bar{x}_n - 3}{2/\sqrt{n}} \geq \frac{2 + \frac{2}{\sqrt{n}} - 3}{2\sqrt{n}}\right)$. Ce qui conduit

$$\text{à } P\left(Z \geq \frac{-1 + 2\frac{z}{\sqrt{n}}}{2\sqrt{n}}\right) = P\left(Z \geq z - \frac{\sqrt{n}}{2}\right) \geq 0,95$$

$$\Leftrightarrow 1 - P\left(Z \leq z - \frac{\sqrt{n}}{2}\right) \geq 0,95 \Leftrightarrow F\left(\frac{\sqrt{n}}{2} - z\right) \geq F(1,645) \Leftrightarrow \frac{\sqrt{n}}{2} - z \geq 1,645$$

$$\sqrt{n} \geq 2z + 2 \times 1,645 \geq 6,58 \Leftrightarrow n_0 = 43,2964$$

$$\diamond \quad \eta \geq 0,99$$

$n_0 = 63,04$: la taille minimum

Exercice 2.

On dispose d'un échantillon $(X_1, X_2, \dots, X_n)$ d'une variable X qui suit une loi normale d'espérance inconnue m et d'écart-type $\sigma = 1$ pour choisir entre les deux hypothèses :

$$H_0 : m = 1$$

$$H_1 : m = 1,5$$

1-Déterminer la région critique du test de Neyman et Pearson dans le cas où $n = 25$ et $\alpha = 0,05$.

2-Calculer sa puissance

3-Quelle devrait être la taille minimum pour que cette puissance soit supérieure à 0,90 ?

Solution :

1-Avec un raisonnement similaire au précédent, la forme de la région critique est

$$R_0 = \{(x_1, x_2, \dots, x_n) / \bar{x}_{25} \geq 1,33\}$$

2-La puissance du test est

$$\eta = P(\bar{x}_{25} \geq 1,33 / m = 1,5) = P\left(\frac{\bar{x}_n - 2}{2/\sqrt{25}} \geq \frac{1,33 - 1,5}{1/\sqrt{25}}\right) = P(Z \geq -0,85) = 0,8023$$

3-La taille minimum pour que $\eta \geq 0,90$

$$\begin{aligned}\eta &= P\left(\bar{x}_n \geq 1 + \frac{z}{\sqrt{n}} / m = 1,5\right) = P\left(Z \geq z - \frac{\sqrt{n}}{2}\right) \geq 0,90 \\ \Leftrightarrow 1 - P\left(Z \leq z - \frac{\sqrt{n}}{2}\right) &\geq 0,90 \Leftrightarrow F\left(\frac{\sqrt{n}}{2} - z\right) \geq F(1,285) \\ \frac{\sqrt{n}}{2} - z &\geq 1,285 \Leftrightarrow \sqrt{n} \geq 2z + 2 \times 1,285 \Leftrightarrow n = 34,3396\end{aligned}$$

Exercice 3.

Le revenu annuel des employés d'une entreprise de la place est distribué suivant la loi de Pareto de densité :

$$f(x; \theta) = \begin{cases} \frac{\theta}{x^{\theta+1}} & \text{si } x \geq 1 \\ 0 & \text{sin on} \end{cases}$$

On considère un échantillon $(X_1, X_2, \dots, X_n)$ de cette loi pour choisir entre les deux hypothèses :

$$H_0 : \theta = 4/3$$

$$H_1 : \theta = 8/5$$

1-Déterminer la région critique du test de Neyman et Pearson dans le cas où $n = 400$ et $\alpha = 0,05$.

2-Calculer la puissance de ce test

Solution :

1-Région critique

Construisons d'abord la fonction rapport de vraisemblance

$$\frac{L_0(x_1, x_2, \dots, x_n; \theta_0)}{L_1(x_1, x_2, \dots, x_n; \theta_1)} = \frac{\frac{\theta_0}{x_1^{\theta_0+1}} \times \frac{\theta_0}{x_2^{\theta_0+1}} \times \dots \times \frac{\theta_0}{x_n^{\theta_0+1}}}{\frac{\theta_1}{x_1^{\theta_1+1}} \times \frac{\theta_1}{x_2^{\theta_1+1}} \times \dots \times \frac{\theta_1}{x_n^{\theta_1+1}}} = \frac{\theta_0^n}{\theta_1^n} \left(\frac{1}{x_1^{\theta_0+1}} \times \frac{1}{x_2^{\theta_0+1}} \times \dots \times \frac{1}{x_n^{\theta_0+1}} \right)$$

$$\frac{L_0(x_1, x_2, \dots, x_n; \theta_0)}{L_1(x_1, x_2, \dots, x_n; \theta_1)} = \left(\frac{\theta_0}{\theta_1} \right)^n \left(x_1^{\theta_1-\theta_0} \times x_2^{\theta_1-\theta_0} \times \dots \times x_n^{\theta_1-\theta_0} \right). \text{ En linéarisant cette expression, on a :}$$

$$\ln \frac{L_0}{L_1} = \ln k \Leftrightarrow n(\ln \theta_0 - \ln \theta_1) + (\theta_1 - \theta_0) \sum \ln x_i \leq \ln k$$

$$(\theta_1 - \theta_0) \sum \ln x_i \leq k_1, \theta_1 > \theta_0 \Leftrightarrow \sum \ln x_i \leq C$$

La valeur de C est déterminée par

$\alpha = P(R_0 / H_0) = P\left(\sum \ln x_i \leq C / \theta = 4/3\right)$. Ici, il faut effectuer un changement de variable de la manière suivante :

$Y = \ln X$ et $\bar{y} = \frac{\sum y_i}{n}$. Déterminons la loi de cette nouvelle variable Y par sa fonction de répartition (tel que vu en Statistique-probabilité) puis de sa densité.

Sa fonction de répartition est $G(y) = P(Y \prec y) = P(\ln X \prec y) = P(X \prec e^y) = F(e^y)$

Et sa fonction de densité est $g(e^y) = e^y f(e^y) = \theta e^{-\theta y}$: loi exponentielle de paramètre $E(Y) = \frac{1}{\theta}$ et $V(Y) = \frac{1}{\theta^2}$.

Le théorème central limite nous permet $\frac{\bar{y}_n - 1/\theta}{\frac{1/\theta}{\sqrt{n}}} \sim N(0,1)$. La constante est alors déterminée par

$$\alpha = P\left(\bar{y}_n \leq \frac{C}{n}\right) = P\left(\frac{\bar{y}_n - 1/\theta_0}{\frac{1/\theta_0}{\sqrt{n}}} \leq \frac{C/n - 1/\theta_0}{\frac{1/\theta_0}{\sqrt{n}}}\right) = P\left(Z \leq \sqrt{n}\left(\frac{\theta_0 C}{n} - 1\right)\right) = 0,05. \text{ Par lecture sur}$$

la table statistique, on a :

$$F\left(\sqrt{n}\left(\frac{\theta_0 C}{n} - 1\right)\right) = F(-1,645) \Leftrightarrow \sqrt{n}\left(\frac{\theta_0 C}{n} - 1\right) = -1,645. \text{ D'où la région critique}$$

$$\alpha = P(R_0 / H_0) = P\left(\sum \ln x_i \leq 275 / \theta = 4/3\right)$$

2-Calcul de la puissance du test

$$\eta = P(R_0 / H_1) = P\left(\sum \ln x_i \leq 275 / \theta = 8/5\right) = P\left(\bar{y}_n \leq \frac{C}{n}\right) = P\left(\frac{\bar{y}_n - \theta_1^{-1}}{\frac{\theta_1^{-1}}{\sqrt{n}}} \leq \frac{\frac{C}{n} - \theta_1^{-1}}{\frac{\theta_1^{-1}}{\sqrt{n}}}\right)$$

$$\text{Ce qui conduit à } P\left(Z \leq \sqrt{n}\left(\frac{C\theta_1}{n} - 1\right)\right) = F\left(\sqrt{n}\left(\frac{C\theta_1}{n} - 1\right)\right) = F\left(\sqrt{400}\left(\frac{275 \times \frac{8}{5}}{400} - 1\right)\right) = 0,9772 :$$

forte puissance qui confirme le principe de Neyman et Pearson.

Exercice 4

On dispose d'un échantillon $(X_1, X_2, \dots, X_n)$ d'une variable X qui suit une loi normale d'espérance inconnue m et d'écart-type inconnu σ pour choisir entre les deux hypothèses :

$$H_0 : \sigma = 1$$

$$H_1 : \sigma = 2$$

1-Déterminer la région critique du test de Neyman et Pearson

2-Calculer sa puissance dans le cas où $n = 15$ et $\alpha = 0,05$.

Solution :

N.B : il faut d'abord remarquer qu'ici, l'écart-type est inconnu.

un cheminement similaire au précédent donne les résultats suivants ;

1-Construisons d'abord la région critique ou plutôt la forme de la région critique :

$$\frac{L_0(x_1, x_2, \dots, x_n; 1)}{L_1(x_1, x_2, \dots, x_n; 2)} = \frac{\prod \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i - m)^2}}{\prod \frac{1}{2\sqrt{2\pi}} e^{-\frac{1}{8}(x_i - m)^2}} = \frac{\prod e^{-\frac{1}{2}(x_i - m)^2}}{\prod \frac{1}{2} e^{-\frac{1}{8}(x_i - m)^2}} = \frac{e^{-\frac{1}{2}[\sum (x_i - m)^2]}}{\frac{1}{2^n} e^{-\frac{1}{8}[\sum (x_i - m)^2]}} = 2^n e^{\left[\frac{1}{8}[\sum (x_i)^2] - \frac{1}{2}[\sum (x_i)^2]\right]}$$

$$\frac{L_0(x_1, x_2, \dots, x_n; 1)}{L_1(x_1, x_2, \dots, x_n; 2)} = 2^n e^{-\frac{3}{8}\sum x_i^2}. \text{ La région critique est ainsi donnée par :}$$

$\sum x_i^2 \geq C$. Il faut maintenant déterminer la valeur de C pour donner une forme définitive à cette région en utilisant le risque de première espèce qui est la probabilité de rejeter l'hypothèse nulle H_0 alors même qu'elle est vraie :

$\alpha = P\left(\sum X_i^2 \geq C / H_0\right)$. Étant donné que nous avons rappelé au cours magistral que le carré d'une variable aléatoire (ou sa transformée) suit une loi du khi-deux à n degrés de liberté, on a alors : $\sum x_i^2 \sim \chi_n^2$. Puisque $\sum x_i^2 \geq C$, on peut directement lire la valeur de C dans la table statistique de χ_n^2 pour $\alpha = 0,05$. $C = 25$. Donc la région critique est

$$R_0 = \left\{ (x_1, x_2, \dots, x_n) / \sum x_i^2 \geq 25 \right\}.$$

2-Calculons la puissance du test

$\eta = P\left(\sum X_i^2 \geq C / H_1\right)$. Puisque $\sum \frac{X_i^2}{4} \sim \chi_n^2$, alors la puissance est

$$\eta = P\left(\frac{1}{4} \sum X_i^2 \geq \frac{C}{4}\right) = 0,975.$$

Exercice 5

Le chef d'établissement d'un grand lycée parisien désire comparer les taux de succès au baccalauréat des trois sections générales. Les statistiques de l'année précédente figurent dans le tableau suivant :

	L	ES	S	Total
Réussite	41	59	54	154
Echec	21	36	75	132
Total	62	95	129	286

Au vu de ce tableau, peut-on considérer que les taux de réussite sont indépendants de la section du baccalauréat?

Exercice 6.

On considère un n-échantillon de variables iid $(X_1, X_2, \dots, X_n)$, avec $n=100$, telle que $X_i \sim N(m, \sigma)$ où m est un paramètre inconnu et $\sigma = 1$. On souhaite tester l'hypothèse suivante :

$$H_0 : m = m_0 = 1, 2$$

$$H_1 : m = m_1 = 1$$

Un économètre propose une région critique de la forme :

$$W = \left\{ x : \bar{x}_n < c \right\}, \bar{x}_n \text{ est une réalisation empirique } \bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \text{ et } c \text{ est la valeur critique}$$

1-Déterminer cette région critique pour un test de niveau $\alpha = 0,05$

2-Calculer la puissance du test

Solution :

1-La probabilité de risque de première espèce peut être exprimée en fonction de la valeur critique c est

$$\alpha = \text{Prob}(W / H_0) = \Phi\left(\frac{c - m_0}{\sigma / \sqrt{n}}\right). \text{ En appliquant la fonction réciproque } \Phi^{-1} \text{ de deux côtés de}$$

l'égalité afin de déterminer la valeur critique c :

$$\Phi^{-1}(\alpha) = \frac{c - m_0}{\sigma / \sqrt{n}} \Leftrightarrow c = m_0 + \frac{\sigma}{\sqrt{n}} \Phi^{-1}(\alpha)$$

Application numérique :

$$c = 1, 2 + \frac{1}{\sqrt{100}} \times (-1, 6449) = 1, 0355. \text{ D'où la région critique}$$

$$W = \left\{ x : \bar{x}_n < 1, 0355 \right\}.$$

2-Puissance du test

$$\eta = \text{Prob}(W / H_1) = \Phi^{-1}\left(\frac{c - m_1}{\sigma / \sqrt{n}}\right).$$

Application numérique :

$$\eta = \left(\frac{1,2-1}{1/\sqrt{100}} + \Phi^{-1}(0,05) \right) = 0,6388 : \text{il y a } 63,88\% \text{ de chance de rejeter l'hypothèse nulle}$$

$H_0 : m = 1,2$ lorsque l'espérance mathématiques des variables X_i est $m = 1$.

Fin de la fiche !